

Exp B LongBench: Model Comparison

Evaluated on original LongBench samples · metrics: QA F1 / Rouge-L F1 / Exact Match

